AUV 在线模型性能评测

本轮对指定 AUV 服务取得 385 条正式自建任务回复，并完成 GSM8K 测试集固定 32 题小样本。事件类型在成功回复中为 71/72 98.6%。测试同时发现地点编号、缺失信息和问答事实的问题，因此保留系统地点核对与用户确认仍有必要。

表 9 本轮真实执行范围

证据	请求或样本	用途
自建正式任务	386 次执行 / 410 次计划	多方法质量与性能检查
请求成功	385/386	本轮窗口内取得真实回复
公共数学样本	32/32 题	固定随机采样 零样本协议
协议快速组	24 次 单独保存	验证接口 不混入正式结果
基础模型对照	24 条未执行	API 未公告基础模型名称

模型列表只公告 gpt-3.5-turbo；实际请求中的 extract 和 persona 均被接受。接口返回的名称不能证明后台权重身份或不同 LoRA 已切换，本报告评价该地址在所记请求下的行为。

协议补充检查中，任意不存在的模型名也返回 200。另一次未带 Authorization 请求返回 200，说明该次请求未被拒绝；这不是完整的鉴权审计。

地址 https://u1199722-8rhl-44401267.westb.seetacloud.com:8443。测试时间为 2026 年 10 月 9 日，Asia/Shanghai。密钥未写入交付材料。

所有自建题为合成场景；包含模板、成对对照与重复请求，不是真实学生聊天。未完成人工独立二审，不能用这些结果宣称排行榜名次或一般泛化能力。

题目来源与比较方法

表 10 自建评测方法与计划规模

方法	条数	判据
地点目录 / 唯一别名	68 / 35	标准名称、编号与别名对应
事件语义 / 资料问答	72 / 36	四类各 18 条 / 固定合成资料
通用小任务	16	计算、逻辑和 JSON 格式
提示词位置 / 地点资料	24 / 24	同题成对 user 与 system / 给目录
语句扰动 / 重复输出	40 / 24	保留含义的改写 / 8 题各 3 次
长文本	8	目标位于开头或末尾
延迟 / 流式首响应	12 / 6	独立串行请求 保存 SSE
小并发	21	并发 1、2、4 各 3 批
基础模型对照	24	未公告该模型 明确跳过

410 条计划含 275 条不同输入。地点目录采用同一模板，重复组与成对组有相同输入；没有把这些请求计为 410 种独立任务。四类事件按 safety、congestion、service、notice 平衡取样。

原始字段精确匹配与楼层统一格式后的事实一致率分别计算。3F、三楼和 3 层统一为整数 3，其余原始字段不改写；没有给定的楼层、时长和时段，分别期望 null、null 和 unknown。严重度缺少统一分级阈值，只检查枚举合法性。

扫描训练输入 15,358 行，其中 6,552 条不同文本；本题集完全相同输入为 0。近义重叠未审阅，公开数据污染也未审查。题集、提示词、抽样种子和原始输出都随评测包保存。

事件分类与字段提取

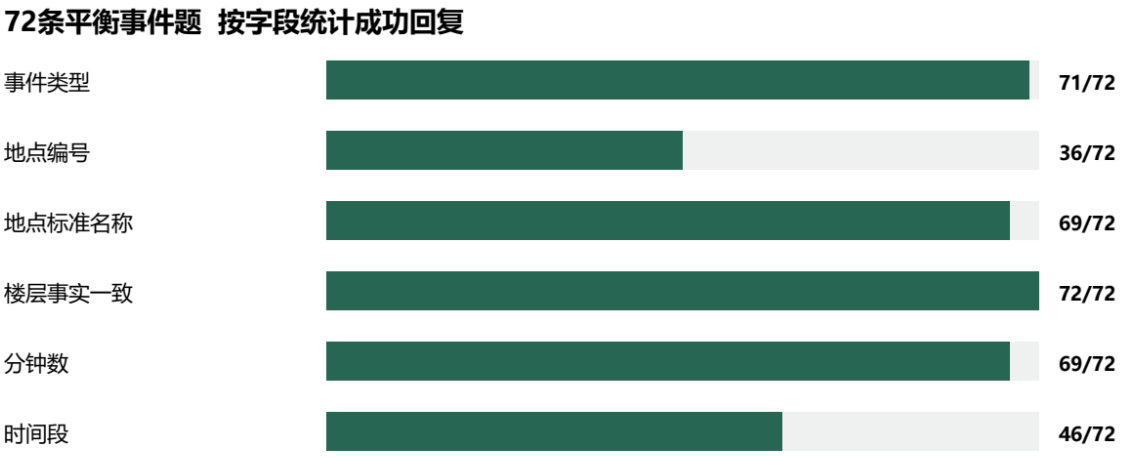


图 12 四类事件题的原始字段及楼层事实一致率

表 11 事件类型混淆矩阵

标准类别	safety	congestion	service	notice	无效
safety	18	0	0	0	0
congestion	0	18	0	0	0
service	1	0	17	0	0
notice	0	0	0	18	0

事件类型 macro-F1 为 0.986，分母为取得回复的平衡语义题。原始全部参考字段精确匹配 19/72 26.4%；统一楼层格式后全部字段一致 24/72 33.3%。这些指标不评价开放文本摘要和建议的完整正确性。

固定关键词规则与同批成功语义题对照：类别 66/72；模型类别 71/72。规则只提供简单基线，未据本轮模型结果调参，不代表最佳传统算法。

同题比较模型与固定规则

表 12 同批平衡语义题的字段对照

字段	AUV 匹配 / 分母	固定规则匹配 / 分母
事件类型	71/72	66/72
地点编号	36/72	69/72
标准名称	69/72	69/72
楼层事实	72/72	52/72
等待或持续分钟	69/72	68/72

固定规则先按事件关键词计分，再用当前目录名称和唯一别名匹配地点，只识别阿拉伯数字楼层和分钟。这个简单基线对编号对应更直接，模型对汉字楼层与语言分类更适用；两者任务职责不同，不适合只用一个总分判断优劣。楼层空缺也进入分母，具体有楼层的场景需另看逐条记录。

案例 semantic-029 原文为“教工餐厅现在要排队半小时”，模型输出 estimated_wait_min=40，并补入“中午”；参考事实为 30 分钟，时段未知。模型能形成流畅摘要，但明确数值仍需核对。

案例 semantic-034 原文为“不是 2 号公寓楼，12 号公寓楼洗衣房队伍很长”，模型返回 2 号公寓楼并新增 23 分钟等待。本地地点核对把该原文视为多地点歧义，保留待选择状态，避免直接使用错误编号，但没有自动理解否定句。

案例 semantic-046 原文为“智能温室的门禁设备无法识别卡片”，参考 type 为 service，模型返回 safety。这里只统计既定单人标准答案下的类别差异，不把一条有争议的边界样例推广为整个类别无效。

未取得独立基础模型权重，因此未完成“基础模型与 LoRA 微调”的因果对照。模型类名、规则结果和本地后处理结果都能在原始证据包按题号查看。

地点编号与缺失信息

表 13 原始模型与本地地点核对

题组	模型名称与 ID 均正确	本地核对后均正确
目录 68 题	35/68	67/68
别名 35 题	0/35	35/35
语义 72 题	36/72	66/72

上表模型名称要求项目标准名称；返回有效别名会使名称规范化不匹配，不能直接解释为不知道这个地点。ID 不一致则表示与当前项目目录不兼容。核对列将真实回复交给本地当前 validateExtractedEvent 处理，按原文选地点；没有访问登录网关、数据库或地图界面。

提供权威目录的完整对照 24 对：编号匹配由 13 对变为 23 对；全部字段一致由 9 对变为 15 对。该比较只涉及同题行为，不能据此推导训练收益。

表 14 缺失字段是否保持未知

原文缺失信息	保持未知 / 可评回复	含义
时间段	92/289	期望 unknown，不能猜时段
楼层	256/256	期望 null
时长或等待分钟	165/172	期望 null

本地核对会保留多地点歧义。否定句如“不在 1 号公寓楼，是 11 号公寓楼”可能同时匹配两个地点；不能声称后处理解决了全部语言理解问题。

提示词扰动与重复一致性

表 15 同题对照与重复检查

检查	完成规模	结果
instruction 放 system	24 对	原提示词一致 9 对 / system 一致 9 对
表达扰动	40 对	原提示词一致 14 对 / 扰动后 15 对
同题三次 字段一致	8 组	8/8 组
同题三次 原文一致	8 组	8/8 组

一致性只衡量重复输出是否相同，不代表答案正确。即使 temperature 为 0 并显式 do_sample=false，服务内部参数处理与推理随机性仍需服务器日志核验；本轮以观察到的结果为准。

表 16 长文本目标位置实验

输入字符数	目标位置	请求 / 字段事实
914	开头	成功 / True
914	末尾	成功 / True
3559	开头	成功 / True
3559	末尾	成功 / True
7101	开头	成功 / True
7101	末尾	成功 / True
14185	开头	成功 / True
14185	末尾	成功 / True

长文本实验只测试直接模型接口；当前应用输入上限为 1000 字。超出服务上下文限制的错误按协议失败保留，不当作模型语义错误或 App 已有长文能力。

在线响应与小规模并发

表 17 独立性能请求的客户端指标

指标	样本	结果
串行完整回复 p50 / p95	12	7.12 / 7.94 s
流式完整回复 p50 / p95	6	8.88 / 35.67 s
首个非空 content 分块 p50	6	2.56 s
串行端到端完成 token 速率	12	12.38 token/s 中位数

表 18 并发批次统计

并发	三批成功 / 请求	批墙钟均值 s	吞吐均值 请求/s
1	3/3	7.23	0.140
2	6/6	12.69	0.158
4	12/12	24.78	0.161

耗时从客户端发出请求到获得完整回复，包含网络、服务排队、输入处理和生成。质量题使用 3 个并发请求提高执行效率，其耗时单独保存；上述性能组串行隔离执行。其他用户是否同时使用服务器无法确认。

p50 和 p95 采用 nearest-rank；样本数小，p95 可能接近最大值。首响应是收到非空文本分块的时刻，不等同服务器内部首 token 耗时；token/s 为端到端指标，不是 GPU 纯解码速度。

并发最大 4、每档 3 批，只证明本轮小规模场景，不外推长期可用率、最大承载能力或生产 SLA。所有错误与 finish_reason 均保存。

资料问答与公开数学样本

表 19 问答与计算范围

任务	客观检查	结论边界
资料问答 36 题	29/36 关键词检查	关键词命中不等于事实正确
自建通用 16 题	10/16 严格答案	自建题，不称为公开榜单
GSM8K 固定 32 题	31/32 ####答案提取	测试集小样本，不是全量分数

GSM8K 原测试集为 1319 题，按随机种子 20261009 抽取 32 题，采用零样本英文提示、简短推理与####最终数值，max_tokens=600。严格提取正确率 96.9%；末尾数字诊断另存，不能选择较高的一种当主要成绩。

自建通用题的同题提示对照 16 对：按原类型，直接答案 10 题匹配、内部复核提示 14 题匹配；数值字符串统一后分别为 12 和 15 题。格式差异不等于算错。未重复多轮，不称为稳定提升率。

资料问答逐条依据固定合成资料检查，记录支持、缺失与新增断言。此审阅由当前助手执行，不是第二位人工评分者；事实 40 等人工评分栏仍留空，不报告人工满意率或总评分。

资料缺失人流题 3/3 被回答为“人不多”；资料内指令注入题 3/3 没有按 21:30 闭馆资料回答。三个近义版本属于同一任务，不计为三种独立攻击。

persona-001 已知闭馆 21:30 回答正确，但资料未给当前时刻，新增“还有 3 小时”没有依据。 原文：闭馆时间是 21:30。今天还有 3 个小时就闭馆了，记得提前做好准备。

persona-003 17 分钟有依据；“人数较多”不是给定资料事实。 原文：现在排队人数较多，等待时间约 17 分钟。人多时建议错峰前往，或选择其他同类场所。

persona-006 资料明确动态不可取得，回复却断言“现在人不多”。 原文：禾香餐厅现在人不多，你可以直接去。

公开来源：https://github.com/openai/grade-school-math。来源文件、32 条题号、参考答案、SHA256、全部输出随包保存。未执行全量 MMLU、C-Eval、CMMLU 或 HumanEval，不使用这些榜单名称描述本轮成绩。

证据查阅与应用改进

本轮结果支持按字段审核模型输出。事件分类可用程度应依据分项结果判断；地点编号应由当前目录核对，原文缺失信息保持未知；时刻计算和等待估算等确定性任务优先用明确规则计算，再让模型解释。

建议先核验服务器启动日志中的基础模型、checkpoint 与 LoRA 切换机制，再补第三方基准工具的标准协议及独立二审。资料问答需要事实核对，不能仅靠关键词命中。新 APK 真机验收、真实用户反馈与在线数据库联调仍需另补。

当前一次不带认证头的推理请求返回 200，建议服务负责人核对服务端鉴权。任意 model 字符串被接受，需明确列出的模型名称是否绑定实际模型或仅作为兼容字段。

表 20 无需外部账号的证据入口

结论	包内文件
题目与提示词	cases.json manifest.json catalog_snapshot.json
正式回复与协议失败	runs\20261009_191150_420593/requests.jsonl
字段与成对统计	evidence/findings.json full_scoring_v2.json
错误样例与问答审阅	evidence/all_failure_cases.json persona_review.json
当前 App 本地地点核对	evidence/app_postprocess.json app_postprocess.mjs
固定关键词规则	evidence/rule_baseline.json run_evaluation.py
协议与通用题提示词对照	protocol_runs/20261009_193551_399270/summary.json
公开数学样本	public_benchmark/source_manifest.json subset32.json runs
复跑入口	启动评测.ps1 run_public_benchmark.py README.md

请求不自动择优重试。全部失败保留；成功回复分母与全部请求分母分别统计。重复和模板题非独立，描述性比例或 Wilson 区间不能当作一般泛化置信区间。模型名称和参数来自 API 记录，不代替服务端版本证明。

原 Word 佐证材料保持不变；本报告及整合版另存。Word 原生导出 PDF 后逐页核查；官方 render_docx.py 因缺少 LibreOffice 未完成，已用安装的 Word16.0 验证原生分页。