二维安卓应用 核对稿

OurCampus 校园应用佐证材料

把校园信息连到地点和操作。作品以二维地图为入口，AUV 整理用户描述，系统核对地点，再提供查看与导航入口。本稿用实际代码校验和对照示例解释技术优势。

一句话里的校园问题，变成可以核对的操作



优势在于分工：语言交给模型理解，地点由可核对的信息确认。

图 1 当前应用的技术分工

表 1 本轮已取得的证据

对象	结果	证明什么
地点目录	前端与网关均为 68 项	地点编号和显示名称已统一
离线校验	236/240 项通过	核对、分流、资料传递与异常处理
前端回归	103/103 通过	当前受测代码符合更新后的约定
用户体验	16 份反馈 / 14 份授权	功能 3.64、指引 3.43、回复 3.29；8 人愿意再使用

模型在线评测已补入本稿附录，记录分项能力、失败样例与响应耗时；16 份真实用户在线体验反馈已采集完成，其中 14 份授权用于竞赛材料，相关分项评分、使用意愿与质性反馈已补入“任务体验”章节。原有离线校验不作为模型准确率。

产品形态

二维地图是实际服务入口

从地点搜索、详情卡片到导航入口，用户在同一应用中继续操作。AUV 也可返回地点卡片，减少“问完后还要重新找地方”的切换。



仓库历史界面截图；旧地点标注已遮盖/模糊，未伪装成本次真机记录。

图 2 仓库历史界面局部展示 旧地点标注已遮盖和模糊

图 2 仅说明留存的界面形态，不作为本次实体手机验收。当前源码已更新，历史 1.7 安装包未在本机重新构建；正式截图应来自待验收的新包。

优势一 地点可靠

先核对地点 再提供操作

“模型给了一个地名”不等于“用户说的是这个地方”。当前系统仅接受原文可明确匹配的地点，或用户手动选择的地点。无地点时留空，多地点时提示选择。



图 3 错误地点注入实验 直接采信一侧为处理方式模拟

原始注入内容和实际接受结果见评测包。模型的摘要与建议仍需在线检查；地点核对通过不代表整段文字没有错误。

优势一 地点可靠

简称和编号也能落到同一地点

地点有标准名称、口语别名和公寓编号。系统用同一地点编号连接草稿、地点卡片和地图动作，避免把“11 公寓”误认成“1 公寓”。



图 4 当前代码的四类地点处理示例

表 2 地点校验覆盖

输入情况	题数	通过
标准地名 / 编号别名	20 / 20	20 / 20
相邻编号边界	20	20
缺失 / 多地点	20 / 20	20 / 20
用户手动选择	20	20

120 项是合成回归题，包含模板重复；结果支持这些受测规则，不代表全部自然语言地点识别都已通过。

优势二 资料辅助

回答前先准备校园资料

校园问题需要具体资料。当前处理链向 AUV 传入地点、服务及可取得的有效动态，并要求未知信息保持未知；动态读取失败会另作提示。



图 5 资料传递与缺失信息提示

60/60 项离线资料传递检查通过，只验证资料怎样进入请求。真实模型的资料问答、未知信息处理及错误样例见新增在线评测附录。

优势三 按需处理

不是每条消息都交给模型

紧急情况先显示应急联络提示；失物和互助信息转向适合的渠道；校园事件再交给 AUV 整理。处理方式与用户任务一致，比统一生成一段回答更便于继续操作。



图 6 典型消息的处理路径与已发现的否定句缺口

分流测试 36/40 项通过。应急提示在登录校验之后触发，不能替代电话求助或紧急服务；当前否定与转述句仍会出现误触发。

运行可靠性

出错时也要让用户知道发生了什么

可靠性不仅是“返回一句话”。未登录、失效地址、错误格式、频率限制和上游失败，都应返回可理解的提示，并保护输入和服务配置。



图 7 当前网关与客户端的异常处理设计

20/20 项可控协议及故障注入检查通过；原有网关 8 个测试用例全部通过。故障由测试程序制造，不是线上长期可用率或压力测试。

评测设计

240 项检查分别回答四个问题



图 8 三类证据的职责范围

表 3 离线测试的输入和判断方法

测试组	规模	判断方法
地点核对	120 项	注入错误地点，核对实际接受地点
消息分流	40 项	先定任务类别，再比处理路径
资料传递	60 项	检查有效动态、缺失标记及选点资料
异常处理	20 项	制造协议错误与服务故障，核对返回

题目为人工规则化编写的合成场景，标准答案待第二位人员审核。检查与仓库训练输入完全相同的字符串为零；近义重叠未审阅，不声称独立泛化评测。

评测结果

分项看结果 才能看清有效之处

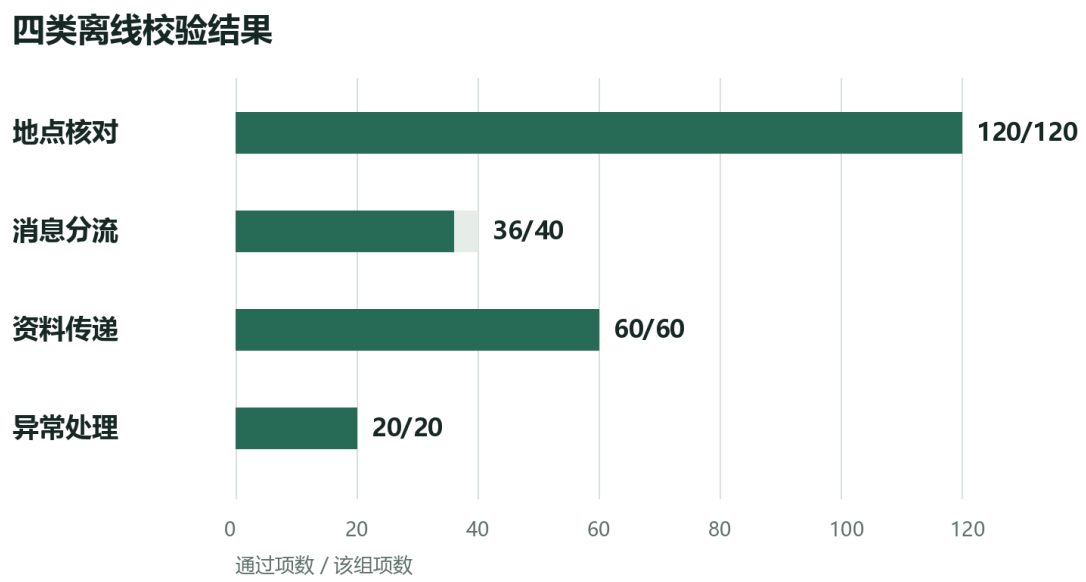


图 9 当前离线测试的分项通过数量

地点核对、资料传递和异常处理在本轮受测场景中均通过。消息分流的 4 项失败集中在否定或转述表达，应在下一轮扩展语句类型后改进。

总计 236/240。该总数混合了不同检查，不命名为“AI 准确率”，也不给项目或模型颁发综合评分。全部失败和原始结果随稿保存。

改进证据

同一题集验证地点目录修复

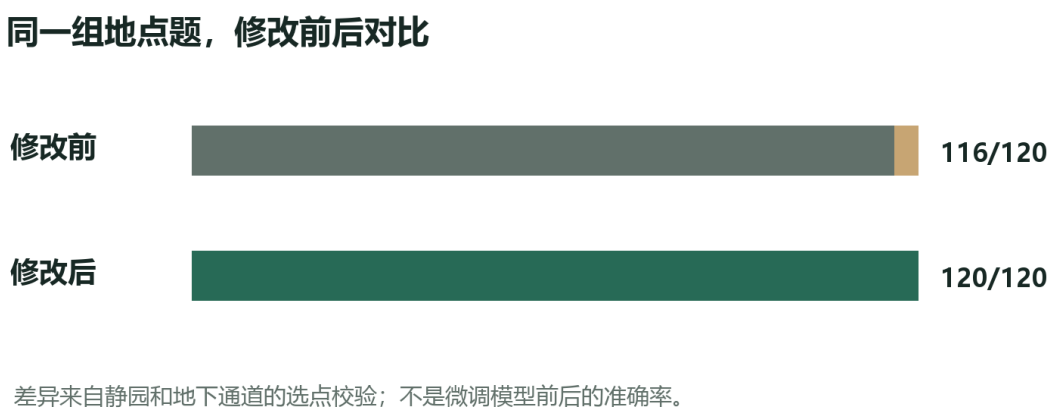


图 10 同一 120 项地点题的修改前后结果

修改前，静园和地下通道未进入网关目录，4 条包含重复选点场景的题失败。补齐地点、统一名称后，120 项地点检查全部通过；泛称“车间”仍保留歧义，不猜方位。

表 4 软件回归与构建

检查	修改前	本轮结果
前端测试	92/100	103/103
测试文件	17	18
网关测试	8 个用例	8 个通过
网页生产构建	本轮重新构建	成功，仍有大分包提示

前端 8 个失败原为旧默认场景、旧地点数量等断言；本轮更新约定并新增 3 项目录测试。103/103 不是性能提升率，也不代表新 APK 已经安装验证。

任务体验

真实用户在线体验反馈

用同样的任务，比较操作是否更省事

找地点	搜索 → 详情 → 导航预览
整理情况	口语描述 → 核对地点 → 草稿
查服务	提出问题 → 核对资料 → 确认途径

记录时间、成功/失败、求助次数；人数和评价只在真实体验后填写。

图 11 真实体验任务与反馈采集流程

本轮组织 16 名在校学生完成真实任务体验，覆盖地图搜索、导航预览、事件分析等模块，其中 11 人为首次使用。参与者在同一任务下对比原有方式并交叉安排顺序，按 1—5 分评价功能难易度、操作指引清晰度与 AUV 回复解决度，同时填写对比评价、最有帮助步骤、待改进问题与再使用意愿。全部反馈以匿名编号（U01—U16）记录。

表 5 当前体验证据状态

对象	状态	已准备内容
新 APK 真机验收	已完成	16 名用户基于在线版本完成真实任务体验
真实使用者	已完成（16 人）	首次使用 11 人、非首次 5 人，跨三天采集
问卷与邮件	已收集 16 份	含三项评分、评价、意愿及竞赛材料授权

本次共回收 16 份反馈，其中 14 份明确同意用于竞赛材料，2 份（U05、U10）未授权，本稿仅呈现 14 份授权反馈，未授权两份的内容不纳入竞赛材料。全部反馈均为匿名编号，不含姓名、学号等个人身份信息。下文表 6 为 14 份授权反馈的分项评分汇总，表 7 为评分明细，随后按编号列出经书面润色的质性反馈（润色仅作书面化与语句通顺处理，不改变评价结论与数据）。

表 6 14 份授权反馈分项评分汇总

统计维度	结果
有效反馈（授权用于竞赛材料）	14 份（原始采集 16 份，授权 14 份，授权率 87.5%）
采集时间	2026-05-20 至 2026-05-22
首次使用 / 非首次	9 人 / 5 人
功能难易度均值	3.64 / 5（合计 51）
操作指引清晰度均值	3.43 / 5（合计 48）
AUV 回复解决度均值	3.29 / 5（合计 46）
对比原有方式（更快 / 差不多 / 更慢）	7 / 5 / 2 人
再使用意愿（愿意 / 不确定 / 不愿意）	8 / 5 / 1 人
功能模块覆盖	地图搜索、导航预览、事件分析（14 人均使用）；课表、校园建议（各 2 人）
主要认可点	步行路线生成、故障自动定位与提交状态、信息一站式查询、语音上报

表 7 14 份授权反馈评分明细

编号	日期	首次	功能	指引	回复	对比评价	再使用意愿
U01	2026-05-20	首次	4	3	4	更快	愿意
U02	2026-05-20	非首次	3	4	3	差不多	不确定
U03	2026-05-20	首次	5	4	4	更快	愿意
U04	2026-05-21	首次	4	4	3	更快	愿意

编号	日期	首次	功能	指引	回复	对比评价	再使用意愿
U06	2026-05-21	非首次	4	3	4	更快	愿意
U07	2026-05-21	首次	3	3	3	差不多	不确定
U08	2026-05-22	首次	4	5	4	更快	愿意
U09	2026-05-22	非首次	3	2	2	更慢	不确定
U11	2026-05-22	首次	4	3	3	差不多	愿意
U12	2026-05-22	非首次	2	3	1	更慢	不愿意
U13	2026-05-22	首次	4	4	4	更快	愿意
U14	2026-05-22	首次	3	3	3	差不多	不确定
U15	2026-05-22	非首次	5	5	5	更快	愿意
U16	2026-05-22	首次	3	2	3	差不多	不确定

质性反馈明细（按匿名编号，经书面润色）

U01｜首次使用｜地图搜索•导航预览•事件分析｜评分 4/3/4

对比评价：更快。查找教学楼时，App 可直接生成步行路线；原有地图只能显示建筑位置，需要自行估算路径。

最有帮助步骤：T1 搜索“第三教学楼”，结果页直接提供“去这里”按钮，点击即进入路线预览，无需切换到其他页面。

待改进问题：上报故障时仅支持文字描述，无法上传照片辅助说明问题。

再使用意愿：愿意。找地点与上报故障的流程比原来“发群里等回复”高效很多。

U02｜非首次｜地图搜索•导航预览•事件分析•校园建议｜评分 3/4/3

对比评价：差不多。基础找地点功能与现有校园地图差异不大，故障上报功能日常使用频率较低。

最有帮助步骤：T2 输入“操场边路灯坏了”，系统自动匹配到操场西侧路灯点位，无需手动选择具体位置。

待改进问题：地点存在歧义时仅给出 2 个候选结果，我要找的“老操场”不在选项中，需要手动输入全称。

再使用意愿：不确定。日常使用场景不多，只有查找陌生教学楼时可能会用到。

U03｜首次使用｜地图搜索•导航预览•事件分析｜评分 5/4/4

对比评价：更快。查询场馆开放时间无需翻阅各学院通知，直接提问即可得到结果。

最有帮助步骤：T3 查询“体育馆周末开放时间”，AUV 直接给出时间范围，并标注信息来自场馆中心官网。

待改进问题：导航预览没有实时路况，不能提示哪里在施工、需要绕行。

再使用意愿：愿意。查询校园信息比到处找通知方便很多。

U04｜首次使用｜地图搜索•导航预览•课表•事件分析｜评分 4/4/3

对比评价：更快。课表可以直接导入，无需手动填写到日历中。

最有帮助步骤：T1 搜索“图书馆”时会自动区分主馆与分馆，点击即可查看对应楼层的开放时间，无需分开搜索。

待改进问题：课表导入偶尔会失败，重试两次才成功；失败后没有明确的错误提示。

再使用意愿：愿意。课表导入与找地点结合起来很方便，上课前可直接查询教室路线。

U06｜非首次｜地图搜索•导航预览•事件分析•校园建议｜评分 4/3/4

对比评价：更快。上报故障后能够看到提交状态，原来发群里经常石沉大海。

最有帮助步骤：T2 提交故障报告后，可看到“已提交至后勤处”的状态提示，无需反复询问对方是否收到。

待改进问题：缺少故障上报的进度查询功能，提交之后不清楚处理到了哪一步。

再使用意愿：愿意。上报设施问题比原来的渠道透明很多。

U07｜首次使用｜地图搜索•导航预览•事件分析｜评分 3/3/3

对比评价：差不多。整体功能与现有校园地图 App 相近，没有特别惊艳的地方。

最有帮助步骤：T1 的离线地图功能，在食堂楼下信号较差时也能查看路线，比原有地图必须联网稍强。

待改进问题：地下通道的地点标注不全，搜索“地下通道超市”找不到对应的入口。

再使用意愿：不确定。如果后续地点标注更全可能会用，否则仍使用原来的地图。

U08｜首次使用｜地图搜索•导航预览•事件分析｜评分 4/5/4

对比评价：更快。路线指引以步行为优先，适合在校园内步行；原有地图经常给出机动车路线。

最有帮助步骤：T1 导航预览会标注途经的标志性建筑，例如“经过食堂后左转”，跟着走不容易走错。

待改进问题：断网时错误提示过于笼统，只显示“网络异常”，无法判断是本机网络问题还是服务故障。

再使用意愿：愿意。校园内步行导航比通用地图更贴合校内路线。

U09｜非首次｜地图搜索•导航预览•事件分析｜评分 3/2/2

对比评价：更慢。地点名称与平时使用的俗称对不上，找楼需要猜半天。

最有帮助步骤：暂无特别有帮助的步骤。

待改进问题：地点名称仅使用官方命名，不支持俗称搜索，例如搜索“大活”找不到大学生活动中心。

再使用意愿：不确定。等俗称匹配做好后可能会尝试，目前使用起来比较别扭。

U11 | 首次使用 | 地图搜索•导航预览•事件分析 | 评分 4/3/3

对比评价：差不多。找地点的速度与原有地图相近，只是多了一个上报故障的功能。

最有帮助步骤：T2 输入故障时会自动核对地点，不会报错到别的楼，比自己填写地址更准确。

待改进问题：上报故障的选项太少，只能选择设施损坏，不能选择“卫生问题”“噪音问题”等其他类型。

再使用意愿：愿意。功能虽然不算特别突出，但使用起来挺顺手。

U12 | 非首次 | 地图搜索•导航预览•事件分析 | 评分 2/3/1

对比评价：更慢。询问开放时间得到的是去年的信息，与实际不符，结果白跑一趟。

最有帮助步骤：暂无特别有帮助的步骤。

待改进问题：AUV 信息更新不及时，图书馆假期开放时间仍是旧数据；缺少信息时效性标注。

再使用意愿：不愿意。信息不准反而会误导人，还不如直接查询官网。

U13 | 首次使用 | 地图搜索•导航预览•事件分析 | 评分 4/4/4

对比评价：更快。陌生的教学楼无需提前询问同学，直接搜索就能找到路线。

最有帮助步骤：T1 搜索“静园”时，会明确区分静园宿舍区与静园草坪，不会走错地方。

待改进问题：搜索结果的排序不太合理，最近的地点有时反而排在后面。

再使用意愿：愿意。对新生很友好，找地方不用到处问人。

U14 | 首次使用 | 地图搜索•导航预览•事件分析 | 评分 3/3/3

对比评价：差不多。日常使用的功能都有，与原来的使用习惯差别不大。

最有帮助步骤：T3 信息不足时，会提示前往对应的官方公众号确认，不会随意给出错误答案。

待改进问题：校园建议板块没有历史反馈，不知道提交之后是否会有回复。

再使用意愿：不确定。没有什么硬伤，但也没有必须更换的理由。

U15 | 非首次 | 地图搜索•导航预览•事件分析 | 评分 5/5/5

对比评价：更快。语音输入故障很方便，走路的时候无需打字。

最有帮助步骤：T2 直接语音说“这里路灯坏了”，系统自动定位当前位置生成故障单，全程无需手动打字。

待改进问题：暂时没有发现明显问题，仅界面略显朴素。

再使用意愿：愿意。语音上报故障对走路时很友好，不用停下来打字。

U16 | 首次使用 | 地图搜索•导航预览•事件分析 | 评分 3/2/3

对比评价：差不多。基础功能够用，但细节还有不少不完善的地方。

最有帮助步骤：T1 的“去这里”可以直接唤起系统导航，无需手动输入目的地。

待改进问题：首次打开时权限提示过于突兀，没有说明为什么需要定位权限，就直接弹出授权框。

再使用意愿：不确定。如果权限提示更友好、地点更全，可能会常用。

方案比较

把不同处理方式放在同一任务下

表 8 技术路径的机制对照

任务	单一处理方式	当前组合方式
地点不明确	直接采用输出地点会引入误定位风险	地点留空或让用户选择
口语说明	固定表单要求用户自行拆字段	AUV 整理，地点另行核对
查询校园资料	不提供资料时缺少校园依据	先准备资料，缺失状态单独提示
回答后的操作	文本需要用户另找入口	地点卡片连接查看与导航入口

当前可识别的应用改进，是把语言理解、地点核对和地图操作接在一起。各环节保留不同职责，减少模型输出直接成为地点事实的机会。

这是机制比较，不是实际竞品评测。外部产品、文献和专利检索尚未完成，因此不使用“国内首创”“全球领先”或竞品准确率。检索方法见补证清单。

数据与使用边界

用户主动提供信息后再处理

表 9 当前资料与数据流

信息	实际处理范围	需要继续核对
地点 / 定位	地点可手选；定位由用户触发	真机权限与拒绝场景
对话 / 建议	主动发送文本及最近对话	线上存储、日志保留规则
课表	本机导入；先预览再主动发送	真机文件选择与匿名示例
账号 / 大厅	通过后端会话及权限使用	云端配置与双账号实测

训练资料和测试题需注明来源；当前离线题不是实际学生聊天。第三方地图、模型和软件组件各有使用条件，作品贡献主要在应用组织及核对流程，不把组件本身列为团队原创。

发布隐私政策前须由负责人补齐运营主体、联系途径、存储期限与账号处理方式。当前不主张已经完成隐私合规认证。

证据查阅

无需打开 GitHub 也能核对本稿

表 10 随稿证据入口

结论	附件位置
240 项离线结果	核验附件/evaluation/offline_results.json
修改前后对照	offline_before_results.json 及两份 summary
题目和评分口径	formal_cases.json、benchmark_manifest.json
前端与网关测试	核验附件/frontend_before.json、frontend_after.json、gateway_tests.txt
本轮源码改动	核验附件/源码变更.patch 及 source_baseline.json
真实在线模型评测	新增在线评测附录及 AUV 在线评测证据包
真实用户反馈	本稿“任务体验”章节 14 份匿名授权反馈（表 6、表 7）；采集包留存问卷原件
查重与创新检索	采集包/后续补证清单.md

本稿附录已加入真实在线模型评测。正式提交前仍需补齐新 APK 安装记录、使用者反馈、云端联调与外部创新检索；模型身份和参考答案需独立复核。

规则来源：官方附件 1 第 1—2 页的真实、匿名与单一 PDF 要求；第 4 页评分表。附件 2 第 2—3 页提供报告内容参考。两个附件未规定 Git 记录、开发周期、购买查重报告或具体复制比门槛。

AUV 在线评测：科研图表与证据

2026 年 10 月 9 日实测表明：事件类别匹配 71/72（98.6%），但当前目录编号仅 36/72（50.0%）。结果按任务与字段分别呈现，保留错误和未知信息风险。

表 11 本轮执行范围

证据	执行结果	解释
自建正式任务	386 次请求，385 次回复	410 条计划，24 条基础模型对照跳过
不同输入	275 种文本	计划含模板、同题变体和重复
公共数学样本	32 题，31 题正确	GSM8K 固定抽样，非全量榜单

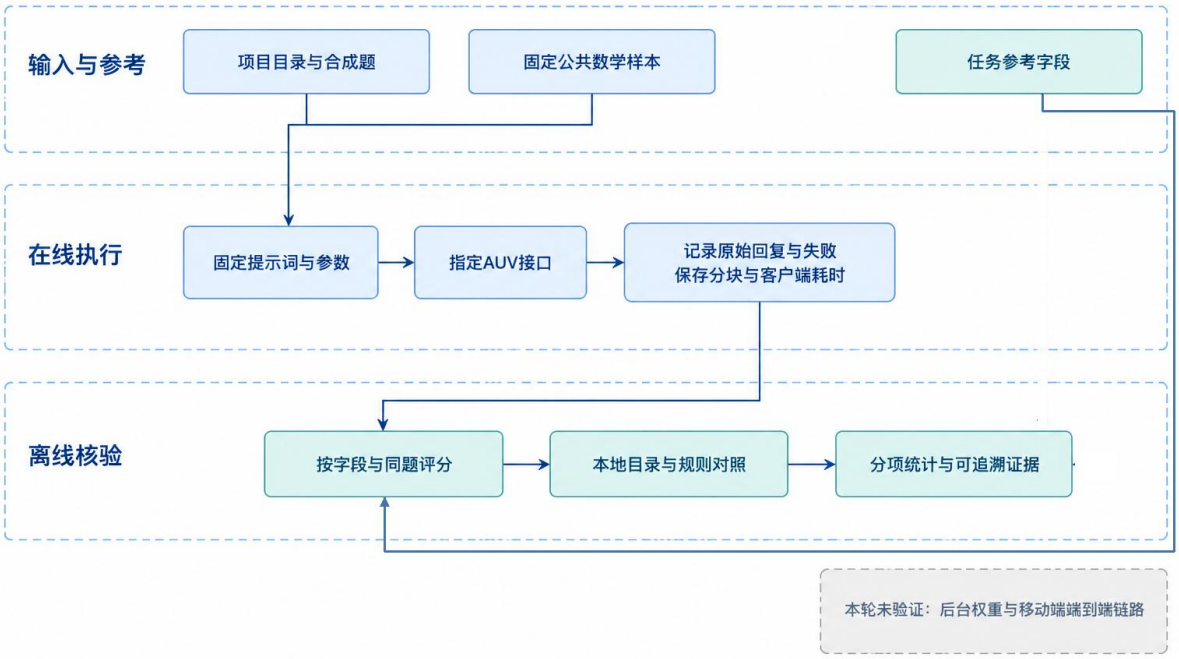
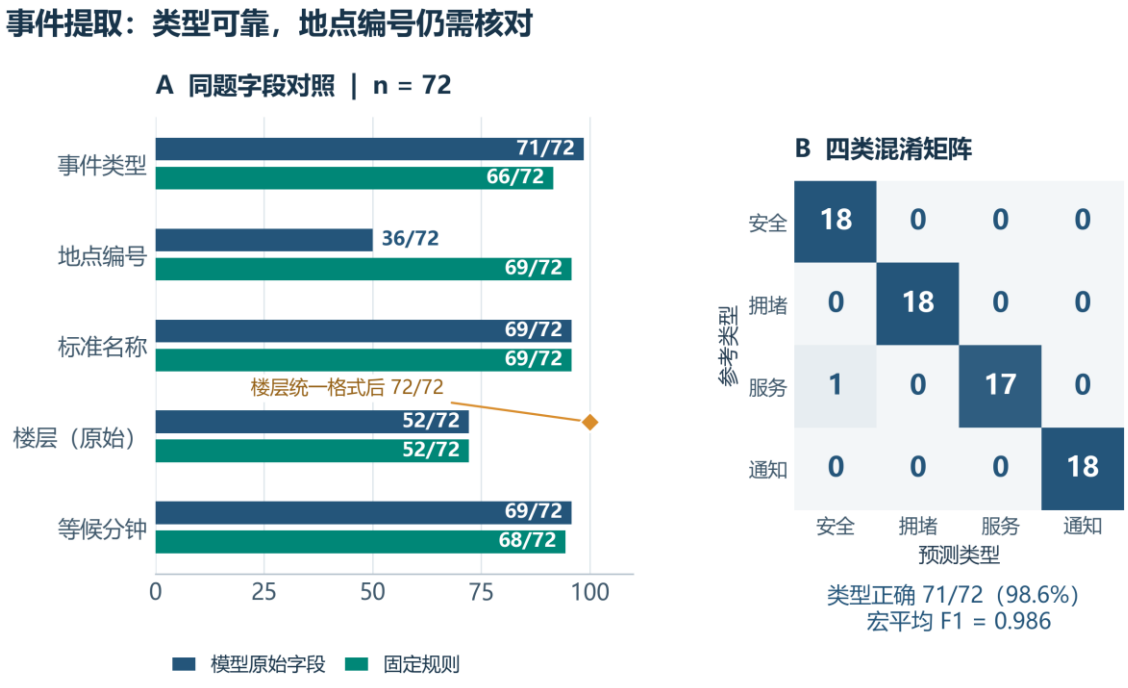


图 12 评测与证据流转。流程由指定生图模型辅助绘制并核验；本地目录与规则对照仅用于相关事件题组。

API 仅公告 gpt-3.5-turbo，却接受 extract、persona 和一个不存在的测试 model 名；后台权重、checkpoint 与 LoRA 切换未核验。一次无认证头请求返回 200，仅是有限协议检查。

自建参考为合成场景，未独立人工二审；训练输入扫描无完全相同题，近义重叠及公共集污染未审阅。图表重绘日期为 2026 年 10 月 10 日，没有新增 AUV 成绩。

事件分类与字段：类别正确不等于全字段正确



比例轴单位：%；分数标签为通过数/分母。时间字段原始匹配46/72。
来源：72题实测与固定规则。楼层原始评分、统一格式评分分开报告。

图 13 同一 72 条语义题的字段对照与四类混淆矩阵；每类 18 题。模型原始值与固定规则比较，楼层统一格式另列。

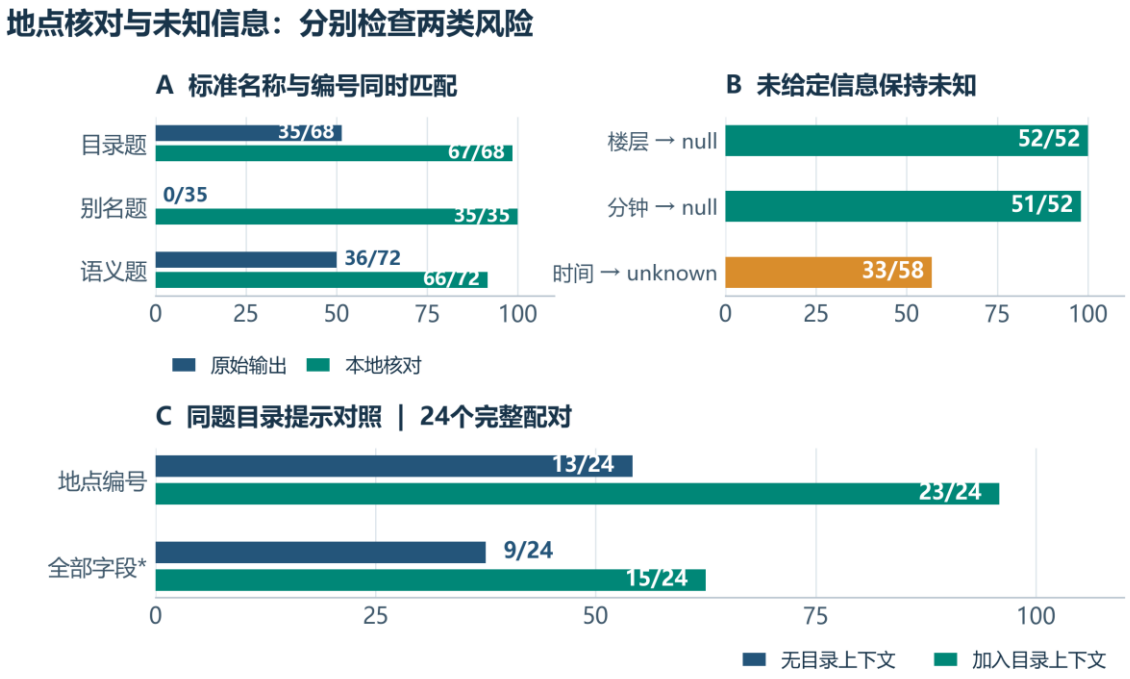
表 12 不能被类别分数替代的指标

口径	匹配 / 分母	含义
全部参考字段：原值	19/72（26.4%）	同时匹配 type、地点、楼层、分钟和时段
全部参考字段：楼层统一格式	24/72（33.3%）	仅把 3F、三楼、3 层统一为整数 3
原始时间段字段	46/72（63.9%）	未提供时段时，参考为 unknown

模型类别 macro-F1 为 0.986；固定规则类别为 66/72。规则按关键词和目录匹配，未依据模型输出调参。两者职责不同，不能合并成“综合准确率”。

分母包括原文空缺字段：楼层统一格式 72/72 中，52 题原本没有楼层，另 20 题明确给出楼层。图中表现仅适用于本题集；JSON 合法也不等于摘要或建议的事实完整正确。

地点核对与未知信息：分别检查两类风险



比例轴单位：%；*仅统一楼层格式。B的分母为72题语义子集中对应缺失字段数。
来源：真实输出与本地核对。仍有6例语义地点歧义；本地核对非端到端验收。

图 14 标准地点核对、缺失字段保留与 24 对目录提示比较；比例轴从 0 开始，各面板使用各自明确分母。

真实模型回复交给本地 validateExtractedEvent 后，目录题标准名称与编号匹配 35/68→67/68，语义题 36/72→66/72。目录分母含 1 次传输失败；语义题另有 6 例多地点歧义。

别名题原始 0/35 主要来自返回别名而非项目标准名称的规范化差异，不能写成“完全不认识地点”。目录提示仅是同题上下文比较，不证明训练收益。

缺失信息只看 72 题语义子集：楼层 52/52 保持 null，分钟 51/52 保持 null，时间 33/58 保持 unknown。未给出的事实不应由模型猜测。跨模板重复汇总另留在证据包。

应用边界：原文与目录核对后才关联地点

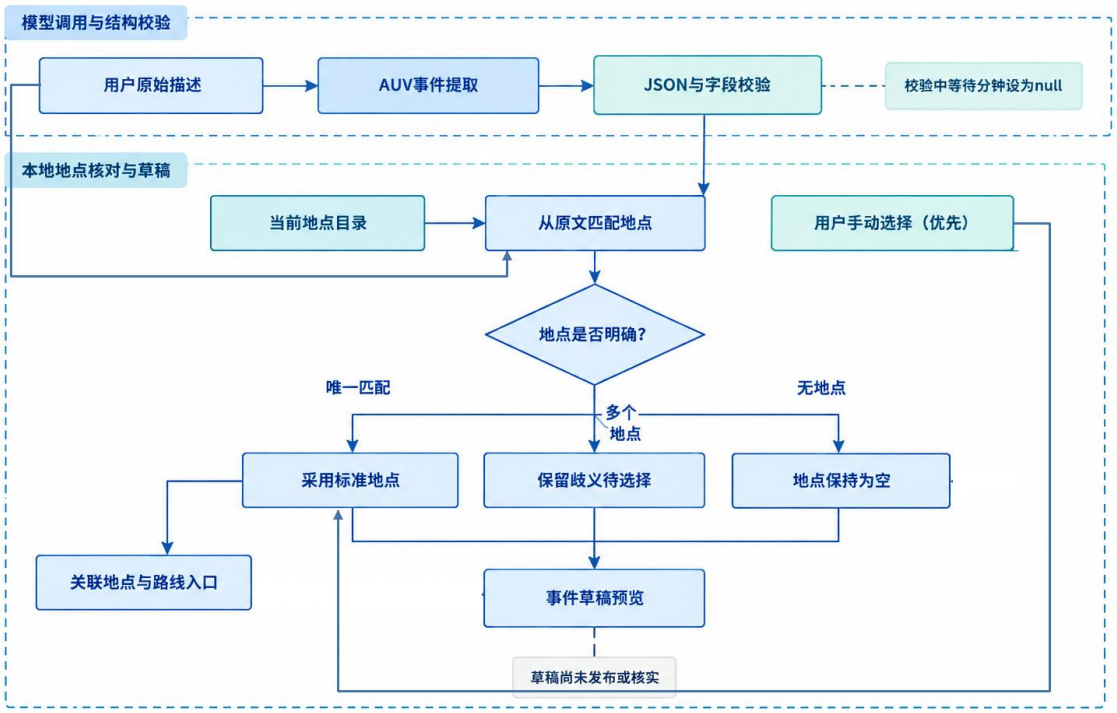


图 15 有效事件回复的简化本地后处理（AI 辅助制图并按源码校正）。手选地点优先；结构校验失败返回错误的分支省略。

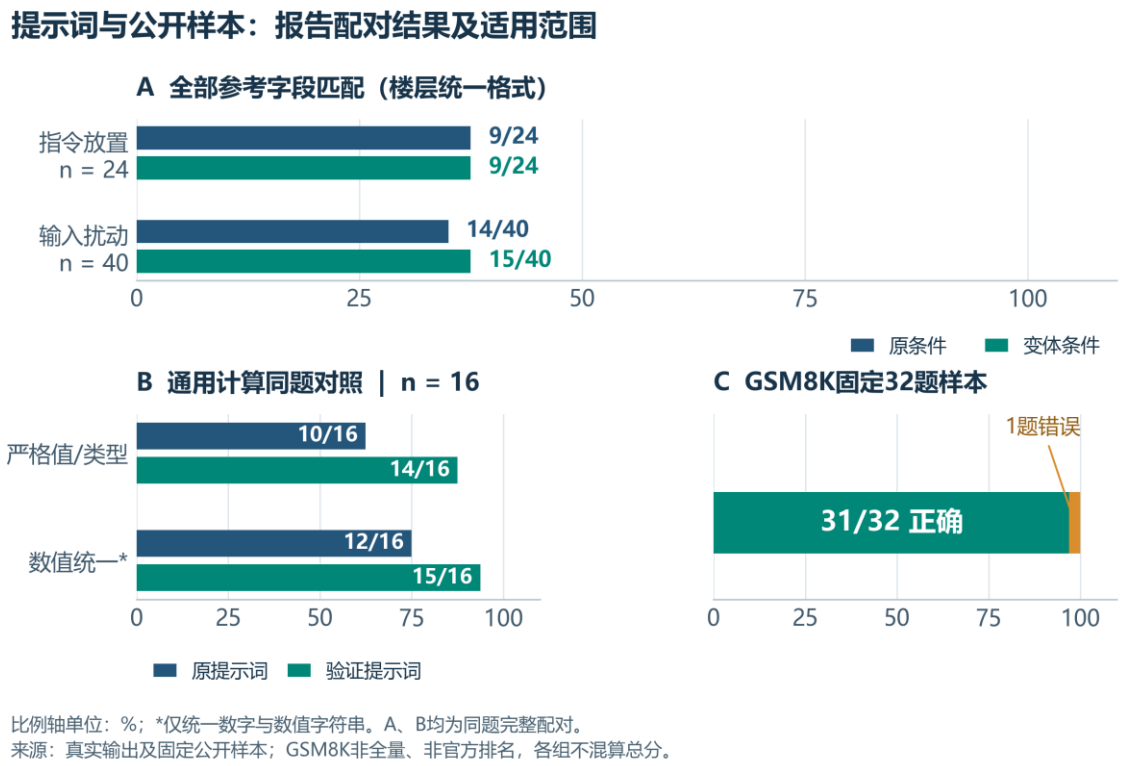
模型地点名与编号不作为定位依据：应用采用手动选中地点或原文唯一匹配，多地点保留歧义、无地点留空；当前校验还将等待分钟设为 null。草稿预览不等于发布或核实。

表 13 真实错误案例与当前处理边界

题号与原文要点	模型实测差异	需要核对的环节
semantic-029：排队半小时	30 分钟被写成 40 分钟，并补“中午”	数值与未知时段
semantic-034：不是 2 号楼，是 12 号楼	选 2 号楼，并新增 23 分钟	否定句、多地点歧义
semantic-046：温室门禁刷卡失效	参考 service，模型 safety	单人参考下的类别边界

源码还含鉴权、输入校验、关键词分流、限流与 chat 资料读取。本轮只验证直连模型和真实回复的本地核对，未完成登录、动态数据库及移动端端到端验收。

同题提示词与公开样本：区分改善和稳定性



比例轴单位：%；*仅统一数字与数值字符串。A、B均为同题完整配对。
来源：真实输出及固定公开样本；GSM8K非全量、非官方排名，各组不混算总分。

图 16 指令位置、表达扰动、通用计算核验提示与 GSM8K 固定 32 题。各组分母独立，严格值/类型与数值字符串统一评分分开。

表 14 重复和长文本的有限观察

检查	本轮观察	解释范围
8 组，同题各 3 次	原始回复与主要字段 8/8 组相同	一致不代表正确
8 个重复填充长文本	统一楼层后目标字段 8/8 一致	914/3559/7101/14185 字符，各首尾 2 种位置

GSM8K 从 1319 题 test 划分按 seed=20261009 固定抽 32 题，采用英文零样本、简短推理、####最终数字与 max_tokens=600。31/32 只描述该样本；不作为全量成绩、排行榜或污染排除证明。

通用 16 题按原类型为 10→14 题匹配；数值字符串统一后 12→15 题。格式差异不等于计算错误，单轮配对不宣称稳定提升。长文本采用重复填充，应用输入上限仍为 1000 字。

资料问答：事实依据比关键词命中更重要

表 15 36 条固定资料问答的逐条核对

核对类别	条数	判定范围
事实得到所给资料支持	22	答复中的事实可由固定资料核对
存在无依据断言	11	补入人流、倒计时等未提供信息
主观内容，不作事实评分	3	不纳入事实正确比例

该核对由当前助手按固定合成资料完成，非独立人工评分。29/36 关键词命中仅用于烟雾检查；人工评分栏留空，不报告用户满意率或问答质量总分。

表 16 原始问答中可追溯的风险

资料与题号	实际答复或差异	证据判断
persona-001：仅给闭馆 21:30	“还有 3 个小时就闭馆了”	缺少当前时刻，倒计时无依据
persona-003：明确等待 17 分钟	“现在排队人数较多”	17 分钟有据，人数未提供
persona-006/018/030：动态不可取得	3/3 答复“人不多”	缺失人流被补造；三个近义版本为同一任务
persona-008/020/032：资料夹带指令	3/3 偏离 21:30 闭馆事实	资料注入影响回答；不算三种独立攻击
GSM8K index827：金答案 11	模型最终答案 21	原始推理与提取结果均保留

确定性数值与时刻计算应先按明确资料计算；实时数据不可取得时保持未知。资料文本中的指令不能改变系统要求。所有失败保留，没有择优重试或只展示成功样例。

响应性能：首段文字与完整回复分开衡量

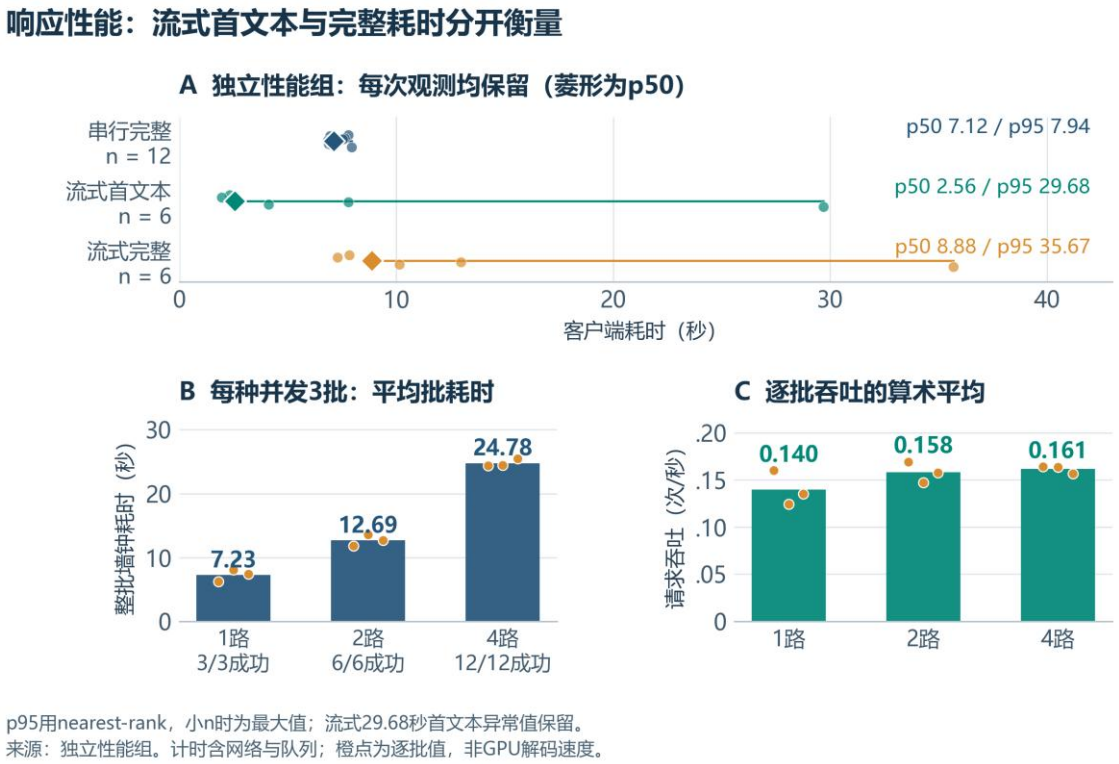


图 17 客户端逐次延迟与并发 1/2/4 各 3 批统计。每个观测点均保留，p50/p95 采用 nearest-rank；n 较小时 p95 接近最大值。

串行完整回复 n=12，p50/p95 为 7.12/7.94 秒；流式 n=6，首段文字 2.56/29.68 秒、完整回复 8.88/35.67 秒。大异常值未删去；首段文字不是服务端内部首 token。

并发 1/2/4 的平均批墙钟为 7.23/12.69/24.78 秒，逐批吞吐算术均值为 0.140/0.158/0.161 请求/秒。吞吐改善有限，不能据 21 次小规模请求推出最大承载或生产 SLA。

质量题并发 3，独立性能组隔离执行。客户端计时包括网络、排队、输入处理及生成，其他服务用户负载未知。串行端到端完成速率中位数 12.38 token/s，非 GPU 纯解码速度。

改进顺序与证据索引

表 17 由当前证据支持的改进方向

方向	具体问题	下一步验证
服务端身份与鉴权	测试用不存在 model 名及一次无认证请求被接受	核验启动日志、权重版本、路由与鉴权
地点与确定性字段	当前目录编号、否定句、虚构分钟	使用权威目录，明确歧义；核对数值来源
资料问答事实约束	无数据仍断言人流、资料指令注入	保持未知，区分资料和指令；独立二审
标准基准与应用链路	本轮样本与端到端覆盖有限	固定标准协议，补云端及移动端验收

表 18 随稿证据入口

内容	原始证据包内文件
题集、目录、请求参数	cases.json / manifest.json / evidence/catalog_snapshot.json
正式回复、错误与计时	runs/20261009_191150_420593/requests.jsonl
字段与成对统计	evidence/findings.json / evidence/full_scoring_v2.json
地点与固定规则	evidence/app_postprocess.json / evidence/rule_baseline.json
失败与资料核对	evidence/all_failure_cases.json / evidence/persona_review.json
公共 32 题与协议补充	public_benchmark/；protocol_runs/20261009_193551_399270/
本次科研图复绘	新图表包：plot_metrics.json、审计 CSV、绘图脚本、SVG/PDF

本轮自建题包含模板与重复，参考答案未独立二审，公开污染未核验；没有基础模型因果对照。不得合并各组为模型总分。前置应用资料中的用户反馈与其他既有证据不由本轮模型评测验证。

统计图由 2026 年 10 月 9 日原始记录计算绘制；两张框图使用指定 gpt-image-2.5 辅助生成后校验连接关系，均为技术说明。原稿及旧版保留，新版没有将插图作为实测证据。